


RAPPORT DE PROJET DE FIN DE MODULE

Filière : Ingénierie en Systèmes d'Information et Big Data -S8

Dand le cadre du module : Ingénierie et maquette numérique – projet AR



Sous le thème :

Conception et déploiement d'un pipeline décisionnel et prédictif de l'attrition client : Application du Machine Learning (LightGBM) et de l'IA Explicable (XAI) au secteur des Télécommunications

Pipeline End-to-End : BigQuery, dbt, LightGBM, SHAP & Power BI.

Encadré par

Pr. Hrimech Hamid

Réalisé par :

- Wissal Cheikh

- Radwa Tourzabi

Table des matières

INTRODUCTION GÉNÉRALE	3
OBJECTIFS DU PROJET	4
Ingénierie des données et déploiement de l'infrastructure dbt/BigQuery	6
Objectif Métier de l'étape dbt.....	14
Implémentation Technique & Résolution des Erreurs Windows	15
MODÉLISATION PRÉDICTIVE ET INTELLIGENCE ARTIFICIELLE EXPLICABLE (XAI)	16
Justification des Choix	17
Comparaison Architecturale : Random Forest vs LightGBM	17
Pourquoi SHAP plutôt que LIME ?	18
Analyse et Commentaires des Graphiques	19
Interprétabilité Avancée avec LightGBM + SHAP (Figures 4 et 5)	22
Synthèse Métier et Interprétation Finale des Variables.....	24
Restitution business et opérationnalisation du tableau de bord Power BI.....	26
Le dashboard Power BI	27
Les indicateurs clés de performance (Cartes KPIs)	28
Spécifications d'industrialisation et architecture cible MLOps sur Vertex AI	33
Conclusion.....	35

INTRODUCTION GÉNÉRALE

À l'ère du numérique, la fidélisation des clients est devenue l'un des piliers stratégiques majeurs pour les opérateurs de télécommunications. Face à un marché hautement concurrentiel et à la fluidité des offres, l'attrition des clients (ou *churn*) représente une perte financière directe et un coût d'acquisition de nouveaux abonnés souvent prohibitif. Pour y faire face, une approche réactive ne suffit plus : les entreprises doivent passer à une stratégie prédictive et proactive.

Ce projet s'inscrit dans cette démarche d'intelligence business. Son but est de concevoir et de structurer une chaîne de valeur Data complète (*End-to-End*), capable de transformer des données brutes issues de différentes sources d'un opérateur télécom en leviers de rétention marketing ciblés.

Afin de garantir l'adoption de ces outils par les équipes décisionnelles, ce projet intègre les technologies d'Intelligence Artificielle Explicable (XAI - *Explainable AI*). L'objectif est de dépasser l'effet "boîte noire" des algorithmes traditionnels en fournissant, pour chaque prédiction, les raisons précises et transparentes qui poussent un client vers la résiliation.

OBJECTIFS DU PROJET

L'objectif général de ce travail est de concevoir et de déployer une architecture décisionnelle et prédictive complète, capable de moderniser la stratégie de rétention client de l'opérateur. Le premier jalon technique de ce projet réside dans l'ingénierie des données. Il s'agit de structurer et de centraliser un entrepôt de données robuste sous Google BigQuery, en orchestrant la transformation et le nettoyage des données brutes (logs d'appels, réclamations et données socio-démographiques) à l'aide de l'outil de modélisation dbt. Cette étape essentielle garantit la qualité, la fiabilité et la conformité des indicateurs de base qui alimenteront l'ensemble de la chaîne décisionnelle.

Une fois l'infrastructure de données stabilisée, le second objectif majeur consiste à développer et optimiser un algorithme de classification avancé à l'aide de la bibliothèque LightGBM. Ce modèle de Machine Learning a pour mission d'anticiper avec précision le risque de départ d'un client à un horizon de 30 jours (J+30). Pour rompre avec l'effet « boîte noire » souvent reproché aux modèles complexes, le projet intègre l'implémentation de la méthode mathématique SHAP. Cet outil d'intelligence artificielle explicable permet d'analyser les variables d'impact à un niveau global, tout en générant des explications individuelles transparentes pour chaque profil de client en situation d'attrition.

Enfin, le dernier axe de ce projet vise la restitution business et la réflexion autour de l'industrialisation. D'une part, les prédictions et les analyses d'explicabilité sont

intégrées au sein d'un dashboard interactif sous Power BI, segmenté en une vue macroéconomique pour la direction et une vue opérationnelle pour le ciblage marketing. D'autre part, le projet intègre la conception de l'architecture cible d'automatisation sur le Cloud via la suite Google Cloud Vertex AI. Cette démarche MLOps formalise les processus indispensables de mise en production, notamment la planification des réentraînements, la gestion des versions des modèles et le déploiement d'API en temps réel.MLOps)**

Ingénierie des données et déploiement de l'infrastructure dbt/BigQuery

La première phase consiste à configurer un projet au sein de la console Google BigQuery à l'aide de l'environnement Sandbox. Afin de permettre à nos outils locaux d'interagir à distance avec cet entrepôt sans intervention humaine constante,

Nous allons accéder au Big Query via le lien suivant :

<https://docs.cloud.google.com/bigquery/docs/sandbox?hl=fr>

et on clique sur accéder à bigquery ,

Avant de commencer

Activer le bac à sable BigQuery

1. Dans la Google Cloud console, accédez à la page **BigQuery**.

Accéder à BigQuery

après la connexion avec ton code google , on commence et on crée une table

Créer une table

Paramètres de partitionnement

☒ Aucun partitionnement

☐ Partitionner par temps d'ingestion

☐ Partition par champ

Pour partitionner par champ, vous devez d'abord ajouter des champs au schéma ci-dessus.

Paramètres du cluster

Ordre de clustering

L'ordre de clustering détermine l'ordre de tri des données. Le clustering peut être utilisé aussi bien sur les tables partitionnées que non partitionnées.

Tags

Les tags vous aident à gérer vos ressources et à leur appliquer des règles. Les tags sont constitués d'une clé de tag unique et d'un ensemble de valeurs de tag. [En savoir plus](#)

Sélectionner le champ d'application des tags

Options avancées

Annuler

Pour permettre à mes outils locaux d'interagir de manière autonome avec cet entrepôt sans exposer mes identifiants personnels, j'ai créé un compte de service IAM spécifique que j'ai nommé "dbt runner"

Google Cloud telecom-churn-xai Tapez / pour rechercher des ressources, des documents, des produits, etc Recherche

IAM et administration / Comptes de service / Créer un compte de service

← Créer un compte de service

1 Créer un compte de service

Nom de compte de service
dbt-runner

Nom à afficher pour ce compte de service

ID du compte de service *
dbt-runner X ↺

Adresse e-mail : dbt-runner@telecom-churn-xai.iam.gserviceaccount.com

Description du compte de service
Décrivez la finalité de ce compte de service.

Créer et continuer

2 Autorisations (facultatif)

IAM et administration / Comptes de service / Créer un compte de service

← Créer un compte de service

Rôle
Administrateur BigQuery

Gère toutes les ressources et données BigQuery

Condition IAM (facultatif) ?
+ Ajouter une condition IAM

Rôle
Administrateur des objets St...



Accorde un contrôle complet sur les objets (répertoire, créer, afficher et supprimer des objets).

Condition IAM (facultatif) ?
+ Ajouter une condition IAM
+ Ajouter un autre rôle

Continuer

Compte de service créé X

À partir de ce compte, j'ai généré et téléchargé une clé d'authentification privée au format JSON



. Cette étape était cruciale car ce fichier détient les privilèges d'accès nécessaires pour que dbt puisse se connecter à distance à mon projet Google Cloud et y modifier les tables.

nous sommes passés à l'installation de dbt-core en local via l'invite de commande PowerShell, car il était indispensable de disposer du moteur d'exécution dbt sur ma machine pour pouvoir compiler nos scripts SQL et piloter les transformations à distance sur BigQuery

Quelques problèmes confrontés à ce niveau

En effet, lors de ma première tentative d'initialisation, le terminal a renvoyé une erreur critique concernant la version de python utilisé, j'ai trouvé Python 3.14 une version incompatible avec les versions stables de dbt,

Pour régler ce problème on utilise un environnement virtuel isolé, que j'ai baptisé `churn_env`, configuré sous une version éprouvée, robuste et validée pour dbt, à savoir Python 3.11.

```
mashumaro.exceptions.UnserializableField: Field "schema" of type Optional[str] in JSONObjectSchema is not serializable
(churn_env) PS C:\WINDOWS\system32> winget install Python.Python.3.11 --silent
Found an existing package already installed. Trying to upgrade the installed package...
No available upgrade found.
No newer package versions are available from the configured sources.
(churn_env) PS C:\WINDOWS\system32> python --version
Python 3.14.0
(churn_env) PS C:\WINDOWS\system32>
```

```
(churn_env) PS C:\WINDOWS\system32> py -3.11 -m venv churn_env
(churn_env) PS C:\WINDOWS\system32> .\churn_env\Scripts\activate
> python --version
Python 3.11.9
(churn_env) PS C:\WINDOWS\system32>
```

```
pip install dbt-bigquery
```

Une fois positionnée au sein de mon environnement virtuel sécurisé `churn_env`, j'ai relancé l'installation de la version stable de dbt pour BigQuery, mais j'ai fait face à un second obstacle technique, à savoir l'erreur critique `ModuleNotFoundError: No module named 'rpds.rpds'`.

Pour résoudre cette anomalie, j'ai exécuté une commande de nettoyage spécifique afin de supprimer de force toutes les dépendances corrompues et mises en cache, y compris pydantic_core.

```
PowerShell
pip install dbt-bigquery --force-reinstall --no-cache-dir
```

Et enfin l'installation a réussi :

```
ModuleNotFoundError: No module named 'pydantic_core.pydantic_core'

(churn_env) PS C:\WINDOWS\system32> pip uninstall dbt-core dbt-bigquery pydantic rpds-py -y
Found existing installation: dbt-core 1.12.0b1
Uninstalling dbt-core-1.12.0b1:
  Successfully uninstalled dbt-core-1.12.0b1
Found existing installation: dbt-bigquery 1.11.1
Uninstalling dbt-bigquery-1.11.1:
  Successfully uninstalled dbt-bigquery-1.11.1
Found existing installation: pydantic 2.13.4
Uninstalling pydantic-2.13.4:
  Successfully uninstalled pydantic-2.13.4
Found existing installation: rpds-py 0.30.0
Uninstalling rpds-py-0.30.0:
  Successfully uninstalled rpds-py-0.30.0
(churn_env) PS C:\WINDOWS\system32>
```

```
(churn_env) PS C:\WINDOWS\system32> dbt --version
Core:
  - installed: 1.11.11
  - latest: 1.11.11 - Up to date!

Plugins:
  - bigquery: 1.11.1 - Up to date!

(churn_env) PS C:\WINDOWS\system32>
```

Une fois l'installation de dbt-core réussie et les bugs de dépendances éliminés, j'ai exécuté la commande `dbt init` dans mon terminal afin de lancer officiellement la création de notre projet d'ingénierie. Pendant cette initialisation, dbt a déployé un assistant interactif qui m'a posé plusieurs questions fondamentales directement dans la console pour configurer les connexions.

```
(churn_env) PS C:\WINDOWS\system32> dbt init churn_pipeline
17:17:45 Running with dbt=1.11.11
17:17:45 Creating dbt configuration folder at C:\Users\Administrator\.dbt
17:17:45
Your new dbt project "churn_pipeline" was created!

For more information on how to configure the profiles.yml file,
please consult the dbt documentation here:

  https://docs.getdbt.com/docs/configure-your-profile

One more thing:

Need help? Don't hesitate to reach out to us via GitHub issues or on Slack:

  https://community.getdbt.com/

Happy modeling!

17:17:45 Setting up your profile.
Which database would you like to use?
[1] bigquery

(Don't see the one you want? https://docs.getdbt.com/docs/available-adapters)

Enter a number:
```

```
Happy modeling!

17:17:45 Setting up your profile.
Which database would you like to use?
[1] bigquery

(Don't see the one you want? https://docs.getdbt.com/docs/available-adapters)

Enter a number: 1
[1] oauth
[2] service_account
Desired authentication method option (enter a number): 2
keyfile (/path/to/bigquery/keyfile.json): C:\Users\Administrator\Downloads\Churn_project\telecom-churn-xai-069057891815.json
project (GCP project id): telecom-churn-xai
dataset (the name of your dbt dataset): raw_telecom
threads (1 or more):
threads (1 or more): 4
job_execution_timeout_seconds [300]:
[1] US
[2] EU
Desired location option (enter a number): 1
17:28:31 Profile churn_pipeline written to C:\Users\Administrator\.dbt\profiles.yml using target's profile_template.yml
and your supplied values. Run 'dbt debug' to validate the connection.
(churn_env) PS C:\WINDOWS\system32>
```

Une fois l'assistant terminé, dbt aura automatiquement généré mon projet et configuré le fichier masqué profiles.yml.:

J'y ai lancé le diagnostic dbt debug afin de vérifier que mon ordinateur parvenait enfin à s'authentifier et à communiquer de manière bidirectionnelle avec mon entrepôt Google Cloud BigQuery avant de commencer à coder.

```
(churn_env) PS C:\WINDOWS\system32> cd churn_pipeline
(churn_env) PS C:\WINDOWS\system32\churn_pipeline> dbt debug
```

```
17:30:01 Running with dbt=1.11.11
17:30:01 dbt version: 1.11.11
17:30:01 python version: 3.11.9
17:30:01 python path: C:\WINDOWS\system32\churn_env\Scripts\python.exe
17:30:01 os info: Windows-10-10.0.26100-SP0
17:30:02 Using profiles dir at C:\Users\Administrator\.dbt
17:30:02 Using profiles.yml file at C:\Users\Administrator\.dbt\profiles.yml
17:30:02 Using dbt_project.yml file at C:\WINDOWS\system32\churn_pipeline\dbt_project.yml
17:30:02 adapter type: bigquery
17:30:02 adapter version: 1.11.1
17:30:02 Configuration:
17:30:02   profiles.yml file [OK found and valid]
17:30:02   dbt_project.yml file [OK found and valid]
17:30:02 Required dependencies:
17:30:02   - git [OK found]
```

```
17:30:02 Connection:
17:30:02   method: service-account
17:30:02   database: telecom-churn-xai
17:30:02   execution_project: telecom-churn-xai
17:30:02   schema: raw_telecom
17:30:02   location: US
17:30:02   priority: interactive
17:30:02   maximum_bytes_billed: None
17:30:02   impersonate_service_account: None
17:30:02   job_retry_deadline_seconds: None
17:30:02   job_retries: 1
17:30:02   job_creation_timeout_seconds: None
17:30:02   job_execution_timeout_seconds: 300
17:30:02   timeout_seconds: 300
17:30:02   client_id: None
17:30:02   token_uri: None
17:30:02   compute_region: None
17:30:02   dataproc_cluster_name: None
17:30:02   gcs_bucket: None
17:30:02   dataproc_batch: None
17:30:02   Registered adapter: bigquery=1.11.1
17:30:09   Connection test: [OK connection ok]
17:30:09 All checks passed!
```

Pour industrialiser la préparation de nos données directement au sein du Data Warehouse Google Cloud BigQuery, nous avons implémenté **dbt** (*Data Build Tool*). Cette étape se situe en amont de la modélisation pour garantir que l'algorithme s'entraîne sur une donnée propre, standardisée et historisée.

Objectif Métier de l'étape dbt

Les données brutes de l'équipe Télécom contiennent souvent des anomalies, des formats incohérents ou des variables mal typées. L'objectif de dbt ici est de créer une couche de staging sécurisée (stg_customer_churn), automatisant le nettoyage pour que les équipes Data Science et Business disposent d'une table unique, fiable et prête à l'emploi.

Implémentation Technique & Résolution des Erreurs Windows

Le déploiement de dbt s'est structuré à travers les étapes clés suivantes :

1. **Isolation de l'environnement** : Création d'un environnement virtuel Python 3.11 (churn_env) sous Windows PowerShell pour éviter tout conflit de version.
2. **Installation du connecteur Cloud** : Installation du package spécifique dbt-bigquery pour exécuter les transformations directement dans le Cloud sans surcharger la machine locale.
3. **Résolution du bug de Profile** : Lors de l'initialisation du projet (dbt init churn_pipeline), dbt a levé l'erreur Could not find profile named 'churn_pipeline'. Ce problème classique d'arborescence a été résolu en créant un fichier profiles.yml local et en adaptant la commande d'exécution.
4. **Création du Modèle SQL** : Développement du script SQL de nettoyage dans l'arborescence models/stg_customer_churn.sql.
5. **Compilation et Matérialisation** : Exécution réussie via la commande :

dbt run --profiles-dir .

Cette commande a forcé dbt à s'authentifier auprès de BigQuery via notre clé de sécurité JSON, compilant le code SQL en une vue propre directement disponible dans BigQuery.

MODÉLISATION PRÉDICTIVE ET INTELLIGENCE ARTIFICIELLE EXPLICABLE (XAI)

Dans le cadre de ce projet de prédiction du *Churn*, une démarche scientifique en deux étapes a été adoptée. Nous avons d'abord entraîné un modèle de référence (*Baseline*) avec l'algorithme **Random Forest** pour analyser les premières importances de variables, avant d'optimiser nos prédictions avec l'algorithme **LightGBM** couplé au framework d'explicabilité **SHAP**.

Justification des Choix

Comparaison Architecturale : Random Forest vs LightGBM

Bien que le *Random Forest* et le *LightGBM* soient tous deux basés sur des arbres de décision, ils construisent leur logique de prédiction de manière totalement opposée :

- **Méthode d'apprentissage (Bagging vs Boosting) :** Le *Random Forest* s'appuie sur le *Bagging* : il crée plusieurs arbres indépendants en parallèle et fait la moyenne de leurs votes. Si un arbre fait une erreur, les autres ne le savent pas. *LightGBM* utilise le *Gradient Boosting* : les arbres sont construits en série, les uns après les autres. Chaque nouvel arbre se concentre uniquement sur la correction des erreurs commises par le précédent, ce qui offre une précision bien supérieure sur les clients difficiles à identifier.
- **Croissance des arbres (Level-wise vs Leaf-wise) :** Le *Random Forest* développe ses arbres niveau par niveau (*Level-wise*), de manière symétrique. *LightGBM* utilise une croissance par feuille (*Leaf-wise*) : il repère directement l'endroit où l'erreur est la plus grande et fait grandir

l'arbre

uniquement sur cette branche spécifique, capturant des interactions de variables beaucoup plus fines.

- **Performance et Vitesse :** Grâce à sa gestion par histogrammes des variables continues (regroupement des valeurs en tranches), *LightGBM* (Light Gradient Boosting Machine) est infiniment plus rapide et adapté aux architectures Cloud modernes (BigQuery, Vertex AI) que le Random Forest, qui devient très lourd sur de grands volumes de données.

Pourquoi SHAP plutôt que LIME ?

Pour ouvrir la "boîte noire" de notre modèle final LightGBM, le framework **SHAP** (*SHapley Additive exPlanations*) a été préféré à *LIME* :

- **Rigueur mathématique et Stabilité :** Fondé sur la théorie des jeux, SHAP garantit une explication stable et déterministe. LIME, à l'inverse, génère des données aléatoires autour
- d'un client pour créer une approximation locale, ce qui induit une instabilité chronique (deux exécutions sur le même client peuvent donner des explications différentes).
- **Dualité Globale/Locale :** LIME ne sait expliquer qu'un client à la fois. SHAP offre une double lecture : il explique chaque client individuellement, mais sait aussi compiler l'ensemble des données pour dresser une cartographie de l'importance globale sur les 7 043 clients.l'entreprise.


Analyse et Commentaires des Graphiques

```
Données d'entraînement : 5634 clients
Données de test : 1409 clients


Entraînement de l'intelligence artificielle en cours...
Modèle entraîné avec succès !

--- PERFORMANCES DU MODÈLE ---
Précision globale (Accuracy) : 80.27%
```


	precision	recall	f1-score	support
0	0.84	0.90	0.87	1035
1	0.66	0.53	0.59	374
accuracy			0.80	1409
macro avg	0.75	0.72	0.73	1409
weighted avg	0.79	0.80	0.80	1409



Distribution du Churn (Figure 1) : Le dataset présente un déséquilibre de classe classique avec environ 5 200 clients fidèles (False) contre 1 800 clients partis (True). Ce déséquilibre a nécessité l'utilisation de poids de classe équilibrés lors de la modélisation.



Analyse Statistique par Boxplots (Figure 2) : L'analyse des variables continues montre des corrélations métiers fortes. Pour l'ancienneté (*tenure*), la médiane des clients qui partent s'effondre à seulement 10 mois (contre 38 mois pour ceux qui restent). Pour la tarification (*MonthlyCharges*), la médiane des clients qui partent est nettement plus élevée (proche de 80 \$ contre 65 \$).



Importance des variables Random Forest (Figure 3) : Le premier modèle Random Forest isole le trio de tête historique : l'ancienneté (tenure), les charges totales (TotalCharges) et les charges mensuelles (MonthlyCharges). Il met également en lumière l'impact des options techniques comme la fibre optique (InternetService_Fiber optic) et le paiement par chèque électronique (PaymentMethod_Electronic check).

Interprétabilité Avancée avec LightGBM + SHAP (Figures 4 et 5)


```

=== 🎨 PERFORMANCES DE TON MODÈLE LIGHTGBM ===
      precision    recall  f1-score   support


 0.0         0.89    0.76    0.82     1035
 1.0         0.52    0.74    0.61      374

 accuracy
macro avg         0.71    0.75    0.72     1409
weighted avg         0.79    0.75    0.76     1409
  
```

En basculant sur le modèle LightGBM analysé par SHAP, l'interprétation gagne en finesse et en certitude mathématique.



Importance Globale SHAP (Figure 4 - Barres Bleues) : SHAP réorganise l'importance et place le type de contrat (Contract) comme le facteur numéro 1 qui influence le modèle, suivi immédiatement par la fidélité (tenure) et les frais mensuels (MonthlyCharges). Le modèle d'IA comprend que la structure de l'engagement (contrat court vs long) est le levier de rétention le plus puissant de l'entreprise.



Impact Granulaire SHAP (Figure 5 - Beeswarm Plot) : Ce graphique en essaim apporte la nuance des couleurs (Rouge = Valeur élevée, Bleu = Valeur faible) :

- Tenure : Les points rouges (forte ancienneté) sont à l'extrême gauche, prouvant mathématiquement qu'une grande fidélité réduit drastiquement le risque de Churn.

- MonthlyCharges : Les points rouges (grosses factures) s'étirent vers la droite, confirmant que les clients payant le plus cher ont une forte tendance à fuir.
- PaperlessBilling : Les points rouges groupés à droite révèlent que les clients ayant une facturation dématérialisée présentent un risque de départ accru.

Synthèse Métier et Interprétation Finale des Variables

L'alignement et la convergence entre les résultats du Random Forest et du LightGBM + SHAP permettent de valider scientifiquement le portrait-robot du client à haut risque :

Le client le plus susceptible de résilier est un client récent (moins de un an d'ancienneté), sans engagement contractuel à long terme (contrat au mois le mois), et supportant une charge financière mensuelle élevée (supérieure à 80 \$).



Recommandations stratégiques basées sur la convergence des deux modèles :

1. Friction de l'offre Fibre & Chèques Électroniques : Identifiée par le Random Forest et confirmée par SHAP, l'association de la fibre optique et du paiement par chèque électronique génère du Churn. Cela suggère soit une insatisfaction liée au prix de la fibre, soit un irritant lors du processus de paiement non automatisé.
2. **Rôle Protecteur des Services Annexes** : Des variables comme le support technique (*TechSupport*) ou la sécurité en ligne (*OnlineSecurity*), bien que secondaires en importance brute, agissent comme des barrières à la résiliation (points localisés du côté protecteur de l'axe SHAP).

Action Business Finale : Pour endiguer l'attrition, la direction marketing doit impérativement cibler les clients au mois dès leur 6e mois d'ancienneté pour les inciter à basculer vers des contrats annuels, tout en leur offrant des services de sécurité ou de support pour augmenter psychologiquement leur coût de transfert vers la concurrence.

Restitution business et opérationnalisation du tableau de bord Power BI

Le dashboard Power BI



Les indicateurs clés de performance (Cartes KPIs)

Les deux cartes positionnées en tête de page permettent aux décideurs d'avoir une visibilité immédiate et chiffrée sur la volumétrie et la criticité du phénomène d'attrition au sein du périmètre d'évaluation :

Volume Total de Clients (Count of Partner)




Cet indicateur affiche une valeur de « 1 409 clients ». Elle représente l'intégralité du dataset de test (soit les 20 % de données isolées de notre base BigQuery nettoyée par dbt) que l'intelligence artificielle a dû évaluer. C'est la base statistique qui valide la robustesse de nos pourcentages.


Nombre de Départs Réels (Sum of Vrai_Churn)



En mesurant la somme des valeurs positives réelles, cette carte comptabilise précisément le volume de clients qui ont effectivement résilié leur abonnement dans cet échantillon. Ce chiffre sert de point de comparaison direct avec le graphique en anneau adjacent pour évaluer le taux de couverture et la précision de notre modèle LightGBM.




Ce graphique montre la répartition des départs réels que l'IA a réussi à intercepter. Sur ton écran, on voit un équilibre (52% vs 47%), ce qui prouve que l'algorithme isole de façon très fine la population à risque



C'est la confirmation visuelle directe de ta variable n°1 de SHAP. La barre bleue du contrat au mois le mois (*Month-to-month*) écrase complètement les contrats de 1 ou 2 ans. Le risque est massivement concentré sur les contrats courts.


Page 2 du Dashboard : Analyse Granulaire et Plan d'Action Rétention

La seconde page du tableau de bord Power BI est une vue opérationnelle conçue spécifiquement pour les équipes marketing et les gestionnaires de la relation client. Elle traduit les découvertes de l'IA en leviers d'action concrets.



Ce visuel croise l'Ancienneté (tenure) sur l'axe X et les Frais Mensuels (MonthlyCharges) sur l'axe Y, coloré selon la prédiction de l'IA (Prediction_IA_Churn).

Ce graphique reproduit de manière interactive la logique du graphique Beeswarm de SHAP. On y observe une densification critique de clients à haut risque (représentés par la couleur des prédictions positives) dans le quadrant supérieur gauche. Cela prouve graphiquement aux décideurs que le danger majeur réside chez les nouveaux clients ayant des factures élevées.



Un segment dynamique basé sur la variable 'Prediction_IA_Churn' a été configuré pour filtrer l'intégralité de la page. En sélectionnant la valeur "1" (Le client va partir), la table se met à jour instantanément.

Partner	Contract	Sum of tenure	Sum of Prediction_IA_Churn
False	Month-to-month	3745	342
False	One year	360	10
True	Month-to-month	3133	154
True	One year	984	21
Total		8222	527

Ce tableau extrait la liste brute des ID clients (Partners) identifiés en situation d'attrition imminente par l'algorithme LightGBM. Plutôt que de traiter le problème

de manière globale, l'entreprise dispose ici d'un fichier de prospection ciblé. Les équipes peuvent extraire ces contacts pour déclencher des campagnes anti-churn chirurgicales (offres de réengagement, appels du service client, remises tarifaires).

Spécifications d'industrialisation et architecture cible MLOps sur Vertex AI

Note d'implémentation : Afin de projeter notre prototype local vers une infrastructure d'entreprise, j'ai conçu et documenté l'architecture cible d'industrialisation MLOps sur Google Cloud. **Il est important de préciser que je n'ai pas réalisé le déploiement concret de ces services sur la plateforme, car l'environnement Google Cloud mis à ma disposition était un projet d'évaluation bridé, sans droits administrateurs complets (IAM) et sans budget pour activer les instances payantes de Vertex AI.** Cette section présente donc mon travail de spécification technique théorique pour la mise en production future de notre modèle LightGBM.

Pour inscrire ce projet dans une démarche industrielle, j'ai formalisé l'architecture cible théorique sur Google Cloud Platform selon quatre étapes clés. J'ai d'abord cartographié l'activation des API indispensables comme Vertex AI et Cloud Build. J'ai ensuite planifié la sécurisation de ma clé JSON en prévoyant son stockage au sein de Google Secret Manager pour interdire toute exposition de mot de passe dans le code source. Pour l'automatisation, j'ai configuré le script d'orchestration Python (kfp) pour compiler le pipeline et le soumettre à Vertex AI Pipelines, en prévoyant une règle Cron via Google Cloud Scheduler pour déclencher un réentraînement automatique tous les lundis à 2h00 du matin. Enfin, j'ai intégré la commande de déploiement théorique de mon modèle LightGBM sur un Vertex AI Endpoint sécurisé, transformant l'algorithme en une API temps réel capable de

renvoyer un score de risque dès qu'un conseiller marketing interroge le dossier d'un abonné.

Pour garantir la pérennité de cette intelligence artificielle face aux changements de comportements du marché, j'ai intégré deux mécanismes MLOps avancés dans mon architecture cible, **bien qu'ils n'aient pas été testés en conditions réelles**. D'une part, j'ai modélisé un système de monitoring du drift afin de comparer en continu les caractéristiques des données réelles entrantes avec les données historiques d'entraînement, ce qui permet de lever une alerte automatisée si les profils des consommateurs ouvrent une dérive. D'autre part, j'ai structuré une procédure de déploiement en A/B testing, permettant d'aiguiller un sous-ensemble du trafic vers une version alternative de mon modèle pour mesurer ses performances théoriques par rapport au modèle principal, assurant ainsi une optimisation continue et sécurisée des performances de l'entreprise.

Conclusion

La réalisation de ce projet d'anticipation du churn constitue une réponse technologique et stratégique concrète aux défis de fidélisation auxquels est confronté l'opérateur de télécommunications. En structurant une chaîne de valeur Data de bout en bout, ce travail démontre qu'il est possible de transformer des volumes massifs de données brutes et hétérogènes en un outil d'aide à la décision hautement performant. Le déploiement combiné de Google BigQuery et de dbt a permis d'assainir et de centraliser l'infrastructure d'ingénierie, garantissant la production d'une donnée propre, fiable et immédiatement exploitable par les couches applicatives supérieures.

Sur le plan analytique, la supériorité algorithmique de LightGBM, couplée à la puissance mathématique de la méthode SHAP, a permis d'atteindre le double objectif de performance prédictive et de transparence. L'intégration de cette intelligence artificielle explicable (XAI) au sein d'un dashboard Power BI interactif offre aux équipes marketing une double lecture indispensable : une vision macroéconomique pour le pilotage de la direction et une vision micro-opérationnelle permettant d'isoler instantanément les clients à risque pour déclencher des campagnes de rétention chirurgicales. La valeur de ce projet ne réside donc pas seulement dans sa précision technique, mais dans sa capacité à traduire des probabilités complexes en indicateurs business actionnables.

Enfin, bien que les contraintes d'accès et de budget inhérentes à la plateforme d'évaluation m'aient empêchée de déployer concrètement le modèle sur l'infrastructure payante de Google Cloud, la formalisation théorique de l'architecture cible Vertex AI inscrit pleinement ce projet dans la modernité des pratiques MLOps. La modélisation des pipelines d'automatisation, du monitoring de drift et des tests A/B prouve que la solution a été pensée pour évoluer et se maintenir en conditions réelles de production. En conclusion, ce projet valide la viabilité d'une gouvernance des données moderne, capable d'armer l'entreprise contre l'attrition tout en posant les fondations d'une culture d'entreprise résolument axée sur les données.